주조 불량 유형 예측 — 1조 최종 보고서

포스코 K-뉴딜아카데미 딥러닝 최종 프로젝트 · 7,535샷(학습 5,274 · 시험 2,261) · 지표 macro F1 · 검증 수치는 학습 데이터로 계산했고, 최종 제출 모델은 중간 리더보드(public) 점수를 기준으로 1안으로 정했다

0. 요약

0.5987	10%	SD 0.037	×0.1
중간 리더보드(public) 실제 점수 (공개 기준선 0.2517)	같은 입력이 없는 새 샷에서 잡는 불량 비율	private 크기(1,131샷)에서 점수의 표본 흔들림	운영안(정상 확률 배율) 10:1에서 전수 검사 대비 −9%

- **안 이름**: **1안** = 최종 제출안(점수가 높고 채점 구조에 맞음), **2안** = 현장성을 높인 또 다른 안(불량을 더 적극적으로 잡고, 뒤 사건 입력 없이 실시간 판정이 가능).
- **읽는 순서**: 제출 모델 1안(4절) → 새 입력에서의 한계(6절, 그림 4) → 대응: 경보 기준과 또 다른 안(2안, 7절) → 원인 후보(8절)와 현장 언어(9절).
- **최종 모델**: 랜덤포레스트 + ExtraTrees 확률 평균 + 두 단계 모델(불량 여부 → 불량 종류) 혼합 + 앞뒤 사건의 입력값 40개 추가(입력 25→65개). `python main.py` 한 줄, CPU 약 80초. 중간 리더보드 점수 0.5987(공개 기준선 0.2517).
- **핵심 발견**: 시험 샷의 약 58%는 같은 입력(쌍둥이)이 학습에 있어 93%를 맞힌다.

  같은 입력이 없는 새 샷에서는 **불량 1,182건 중 122건(10%)만 잡고 정상 4,092건 중 73건(1.8%)을 불량이라 한다**. 이 한계는 모델 종류와 무관하다(18개 탐지기 AUC 0.72~0.75).
- **현장 제안**: 모델은 "불량이다"를 단정하는 용도가 아니라 **경보 기준을 놓침 비용에 맞춰 낮춰 검사 대상을 고르는 용도**로 쓴다.

  하루 3,800샷(사이클 시간으로 계산) 기준 운영안은 정상 확률 ×0.1이고, 놓침 1건=헛경보 10건으로 가정하면 전수 검사보다 9% 싸다(5:1이면 24%, 20:1이면 이점 없음 → **결과는 비용 비율에 민감**, 7절). 현장성을 높인 또 다른 안(2안)도 함께 검증했고, 경보 기준을 맞추면 두 모델의 최저 비용은 4% 안이다(4·7절). 공정 관리 후보 구간도 제시하되 원인은 시험 생산으로 확인해야 한다.
- **한계**: ① 같은 입력이 없는 새 샷에서는 불량의 10%만 잡는다.

  ② 최종 모델은 앞뒤 사건의 입력값을 쓰는데, **뒤 사건의 값은 실시간 현장에서는 아직 모르므로** 사후 분석·일괄 선별용이다(앞 사건만 쓰면 이득이 사라진다, 4절 ①). 실시간 적용에는 앞 사건만 쓰는 변형이 필요하다.

  ③ 비용 비율은 가정이며 현장 값으로 교체해야 한다.

- **규칙 준수**: 특징은 전처리된 입력뿐이며 shot_id·id·Shot 열과 정답에서 만든 값, 원본 불량 기록은 쓰지 않았다.

  쌍둥이 묶음은 입력값 비교로 만들어 검증 분할에만 쓴다.

  이웃 *입력*은 쓰지만 이웃의 *정답*은 쓰지 않았다.

  최종 제출 모델은 중간 리더보드 점수(0.5987)를 기준으로 1안으로 정했고, 학습 데이터 검증은 한계와 운영 기준을 보는 데 썼다.

1. 데이터 문제와 처리

문제	확인한 수치	처리와 이유
식별·상수 열	shot_id·id·Shot 3개, Min/Max 상수 8개	제거(식별 열은 규칙상 특징 불가, 상수는 정보 없음). 32열 → 21열 + 표시 열 4개 = 25개
결측	공장 온도·습도 90행(전부 제품 유형 2, 두 덩어리)	앞뒤 실측 30개씩의 중앙값으로 채움 + 결측 표시 열. 방식·창 크기 간 점수 차 0.004(표준편차 0.03 이내)
이상한 값	속도 0·긴 사이클(설비 정지로 보임), 이상치 15행	지우지 않고 표시 열만 추가. 지워도 점수 차가 표준편차 안쪽
중복 행 (쌍둥이)	입력 21개가 앞 행과 같은 행 3,174개(42%), 같은 묶음 안 라벨 일치 97.8%	행은 유지하고 묶음 번호를 검증 분할에만 사용(특징 아님). 시험 데이터도 58%가 같은 구조
클래스 불균형	정상 77.6%, 기타불량 76건·Stain 100건	class_weight(balanced의 0.5제곱). 정확도가 아닌 macro F1 사용
제품·시기 교란	shot 4208에서 제품 전환, 불량 종류가 제품·시기에 몰림(400샷 블록 불량률 1.8~51%)	검증을 묶음·시간순으로 따로 측정(6절), 원인 분석은 제품 유형별로 수행(8절)

2. 설계 카드 (MLP)

입력 25개 → 은닉 128 → 64 → 출력 7, 활성화 ReLU(음수는 0으로 막아 단순한 꺾은선 조합으로 비선형을 표현), 드롭아웃 0.2(과적합 방지), 손실은 클래스 가중 교차엔트로피(희귀 불량을 놓치지 않게), Adam 학습률 1e-3(기본값에서 시작, 손실이 안정적으로 내려감), 가중치 감쇠 1e-4. epoch는 검증 손실이 최저인 18에서 멈춘다(그림 1). 입력은 학습 구간 평균·표준편차로 표준화.

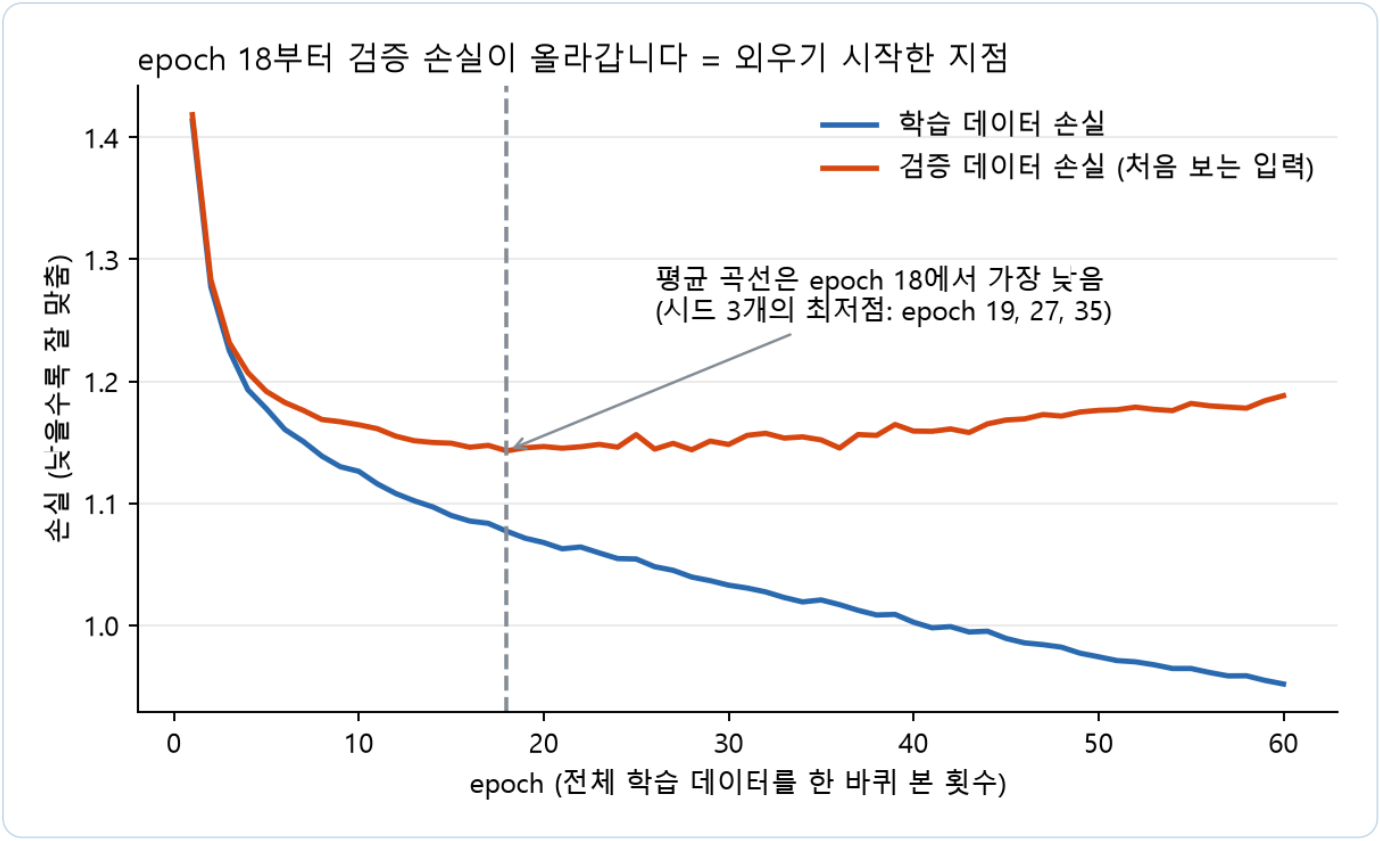


그림 1. 학습 손실은 계속 내려가지만 검증 손실은 epoch 18(1.143)에서 최저, epoch 60에서 1.188로 4% 상승 → 과적합 시작점. 시드 3개 최저점 19·27·35.

3. 베이스라인 대조

모델 (쌍둥이 묶음 검증, 새 입력)	macro F1	비고
공개 기준선(로지스틱 + class_weight, 강사 제공)	0.2517	리더보드 구조
로지스틱 / RF / HGB (잎 10)	0.287 / 0.326 / 0.305	새 입력만 맞히는 어려운 검증
MLP	0.277(탐지율 54%)	리더보드 구조에서는 0.289로 트리(0.58)보다 훨씬 낮음

MLP가 리더보드 구조에서 낮은 이유: 시험의 58%는 학습에 같은 입력이 있는데 트리는 이를 외워 93% 맞히고 MLP는 외우지 못한다.

반대로 새 입력에서는 MLP(0.277)와 트리(0.279)가 같다.

즉 점수 차는 모델 품질이 아니라 "같은 입력을 외울 수 있는가"에서 나온다.

4. 비교 실험 3종 (한 번에 하나만 바꿈, 1안 대비 내부 점수 차이)

바꾼 것	결과	해석
① 앞뒤 사건 입력값 특징 (없음 → 40개)	+0.0045 (앞만 −0.0002, 뒤만 −0.0015)	유일하게 일관된 이득. 앞뒤 샷의 공정 상태가 현재 샷의 불량과 이어진다고 해석. 라벨은 쓰지 않음
② 클래스 가중치 강도 (0.3 / 0.75 / 1.0, 기본 0.5)	−0.0002 / +0.0006 / −0.0007	노이즈 → 0.5 유지. 강하게 줄수록 탐지는 늘지만 헛경보도 늘어 점수는 그대로
③ 잎 크기 (최소 샘플 1 → 2)	0.608 vs 0.610	동일 → 1 유지(탐지 57.4%, 정확도 87.2%)

이 밖에 나무 수 900, max_features, 부트스트랩, 이웃 ±2~3, 시기 군집, 클래스별 탐지기, SMOTE식 보강, 이동평균 등 20여 가지를 시험했으나 모두 ±0.005 이내였고(시드 흔들림 0.005), 어떤 조합도 시험 데이터 예측이 시드에 따라 평균 3행(0.1%) 넘게 바뀌지 않았다.

1안이 평평한 정점이다.

최종 모델 선택 근거: 1안(최종 제출안)과 2안(현장성을 높인 또 다른 안: RF 잎1 + RF 잎6 확률 평균, 기타불량 확률 ×1.5, 입력 25개)을 같은 학습 데이터 검증에서 비교했다.

최종 제출 모델은 실제 리더보드(public) 점수를 기준으로 1안으로 정했다(1안 0.5987, 2안 0.5710). 검증 수치는 이 선택의 한계를 확인하는 데 썼다.

"새 입력"은 쌍둥이를 같은 쪽에 두는 5분할, "새 생산 구간"은 연속 100샷을 통째로 떼는 5분할이며 시드 7·123·2026 평균, 경보 기준은 둘 다 ×1.0이다.

모델	public 점수 (실제 제출)	새 입력 F1 / 탐지율	새 생산 구간 F1 / 탐지율	놓침 / 헛경보 (public 크기 1,130샷 환산)	구조와 용도
1안 (최종 제출안)	**0.5987**	0.258 / 10.3%	0.136 / **1.2%**	106 / **23**	숲 6개·2단계·앞뒤 입력 65개. 채점 구조(쌍둥이 58%)에 맞음, 뒤 사건 입력이 필요해 사후 분석용
2안 (현장성을 높인 또 다른 안)	0.5710	**0.323** / 48.0%	**0.235** / 31.0%	**65** / 106	숲 2개·입력 25개. 불량을 적극 부름, 실시간 가능

리더보드와 같은 구조(시험의 58%가 학습에 같은 입력)에서는 외우는 능력이 점수를 가르므로 1안이 높고, 처음 보는 입력과 새 생산 구간에서는 2안이 불량을 더 잡는다.

1안은 새 생산 구간에서 불량을 거의 못 잡는다(탐지율 1.2%). 불량을 구분하는 능력 자체(AUC)는 두 모델 모두 0.74~0.75로 같고, 1안과 2안의 public 차이 0.028은 private 크기(1,131샷) 표본 흔들림(SD 0.037) 안이다.

1안에 2안의 확률을 섞어도 점수·정확도·새 입력 세 지표를 동시에 올리지는 못했고, 탐지 증가 효과는 1안의 경보 기준 하나로 더 적은 손실로 얻는다(7절). 그래서 제출 CSV는 1안, 현장 운영용으로는 2안을 구분해 제시한다.

5. 학습곡선 (데이터를 더 모아야 하는가)

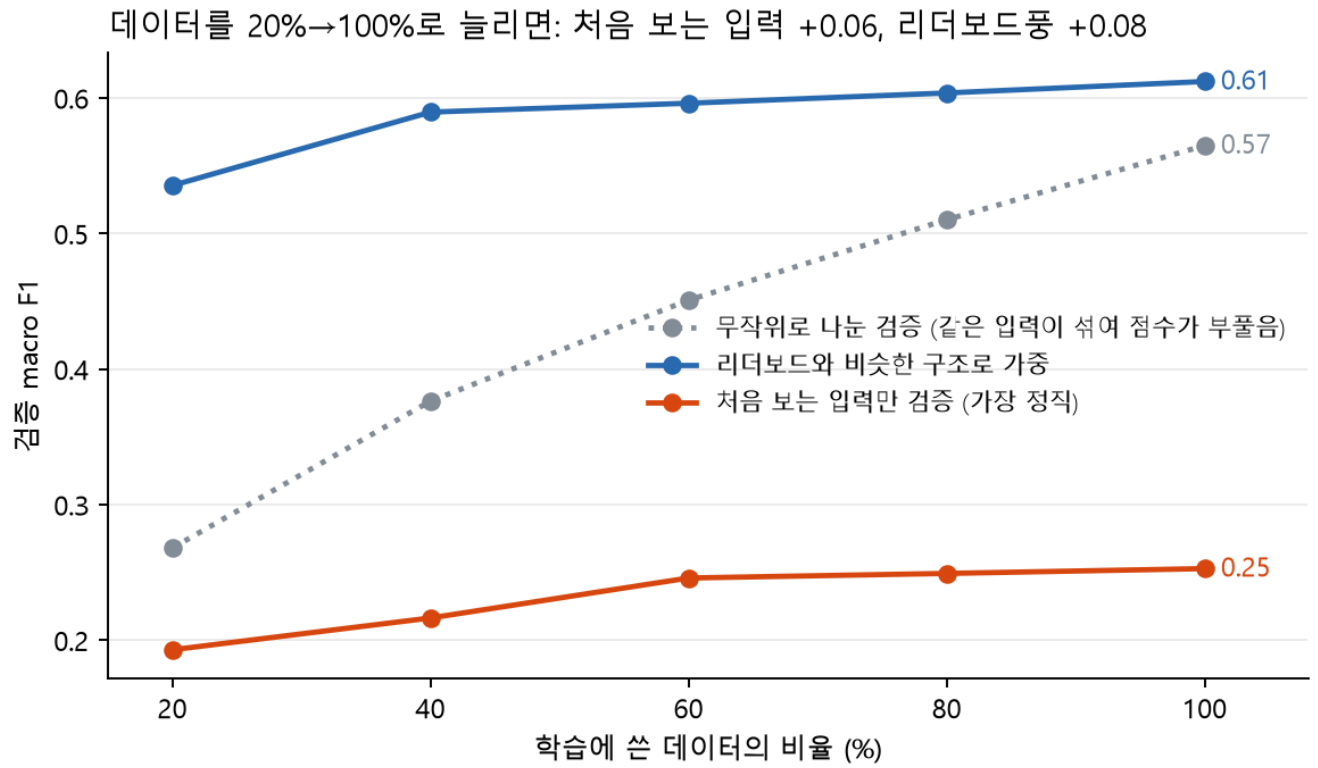


그림 2. 학습 데이터 비율에 따른 점수(1안, 시드 2개). 새 입력 0.193→0.253(60% 이후 평평). 리더보드풍 0.536→0.612, 무작위 CV 0.268→0.565(같은 입력이 학습에 들어와 크게 오름).

결론: 데이터를 더 모으면 "이미 본 조건"의 점수는 오르지만 새 조건의 점수는 거의 안 오른다.

새 조건을 잡으려면 데이터 양보다 **불량과 정상을 가르는 새 측정**이 필요하다.

가정 기반 계산(불량 샷에서 평균 d 표준편차 높은 가상 측정을 추가, 실제 결과 아님): d=0.5는 점수 0.268→0.269로 변화 없고, d=1이면 0.297, d=2이면 0.400(탐지율 14%→41%). 구분력이 표준편차의 약 1배 이상인 측정을 찾아야 의미가 있다.

6. 분할 방식 비교 (어느 쪽이 배포 성능인가)

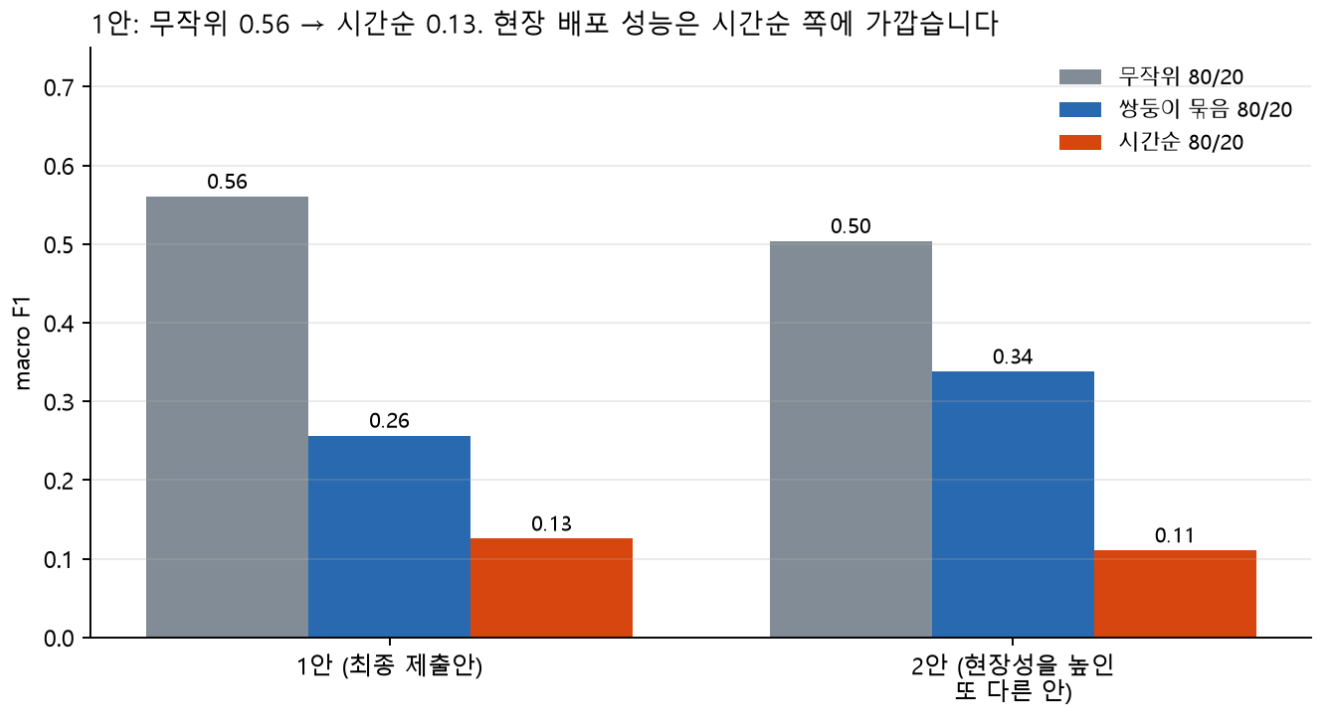


그림 3. macro F1 / 불량 탐지율 / 정확도. 무작위·묶음은 80/20 시드 5개 평균, 시간순은 shot 순 앞 80%로 학습해 뒤 20%를 검증.

모델	무작위 80/20	쌍둥이 묶음 80/20	시간순 80/20
1안(최종 제출안)	**0.560**	0.256	**0.125** (탐지 0%)
2안 (현장성을 높인 또 다른 안)	0.504	**0.338**	0.111 (탐지 31%, 정확도 50%)

외우는 1안은 무작위에서 부풀고 시간순에서는 "전부 정상"(0.125)에 가깝다.

2안은 시간순에서도 불량의 31%를 부르지만 헛경보가 많아 정확도가 50%이고 F1은 0.111로 1안과 같은 수준이다.

현장 배포 성능에 가까운 쪽은 시간순이다.

리더보드는 시험 샷이 생산 순서에 섞여 있어 무작위 쪽에 가깝다.

시간순 구간(shot 6009~7535)은 전부 제품 유형 2이고 학습에 이 제품이 1,269행뿐이어서 "새 시기의 같은 제품"을 거의 못 본 시험이다.

그러므로 최종 점수(private 1,131행, 흔들림 SD 약 0.03)를 현장 성능으로 읽으면 안 된다.

연속 100샷 구간을 통째로 떼는 "새 생산 구간" 검증(4절 표)에서도 같은 결과다: 1안은 F1 0.136·탐지율 1.2%, 2안은 0.235(탐지 31%).

분할에 따라 모델 순위가 바뀐다(1안과 2안 비교): 무작위 분할과 실제 리더보드(public 1안 0.5987, 2안 0.5710)에서는 1안이 높고, 쌍둥이 묶음(새 입력) 기준에서는 2안이 0.34로 1안(0.26)보다 높다.

시험 샷의 58%가 학습에 같은 입력이 있는 구조(private 58.4%, 입력으로 센 값)이므로 최종 채점도 이 구조에 가깝다고 보고, 중간 리더보드 점수도 1안이 높아 1안을 택했다.

대신 새 입력 약점을 한계로 명시하고 운영안은 경보 기준으로 보완했다. private 점수는 1,131샷이라 표본만으로 SD 약 0.037 흔들리므로 점수 예측은 하지 않는다.

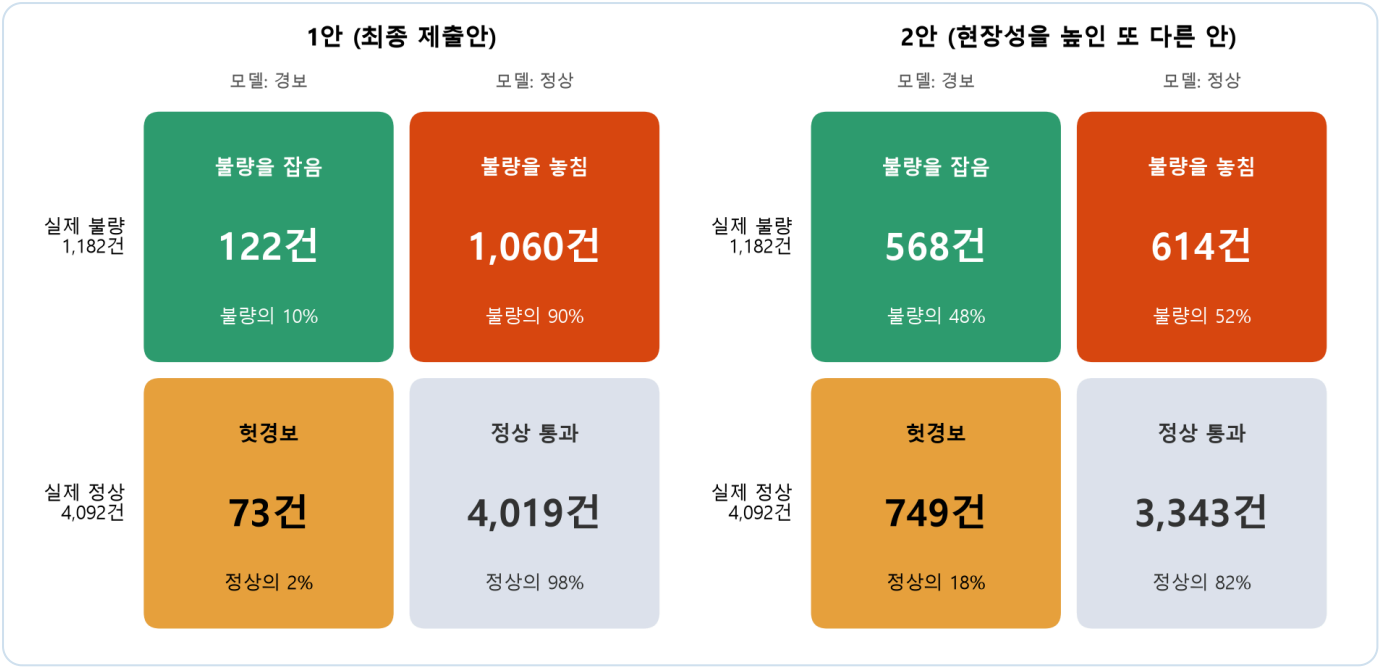


그림 4. 새 입력(쌍둥이를 같은 쪽에 둔 5분할) 기준 정상/불량 2×2 표, 건수는 시드 7·123·2026 평균이며 경보 기준 ×1.0. 1안은 불량 1,182건 중 122건(10%)을 잡고 정상 4,092건 중 73건에 헛경보를 낸다. 2안은 불량을 48% 잡는 대신 헛경보가 18%다. 7절 비용표는 시드 4개 평균이라 이 그림과 몇 건 다르다.

7. 운영 기준 (비용표)

가정과 출처. 하루 생산량은 계산했다: 데이터의 사이클 시간 중앙값 22.6초, 24시간 연속 가동이면 86,400÷22.6 ≈ **하루 3,800샷**(가동 시간은 가정, 8시간 교대면 약 1,270샷). 불량률 22.4%는 학습 데이터에서 계산한 처음 보는 입력 기준이라 하루 불량 약 850건·정상 약 2,950건이다.

비용 비율은 현장 자료가 없어 가정한다: 헛경보(정상 샷을 불량으로 불러 한 번 더 검사) 1건 = 1, 놓친 불량 1건 = 5·10·20. 비용 비율은 부품의 안전 등급·보증/리콜 비용·재검사 비용에 따라 현장마다 다르므로 정확한 값을 알 수 없다.

그래서 **기준안은 10:1**로 두고(품질비용 이론의 "1-10-100 경험 법칙", 검사·재작업 대비 고객에게 나간 불량의 비용이 약 10배, 엄밀한 표준 수치는 아님) 5:1과 20:1에서도 같은 표를 만들어 결론이 유지되는지 본다.

결정 기준은 정상 확률에 곱하는 배율(작을수록 불량으로 더 자주 부른다, `main.py`의 `ALERT_NORMAL_SCALE`)이다.

건수는 학습 데이터 검증(처음 보는 입력, 시드 4개 평균이라 그림 4의 시드 3개 평균과 몇 건 다름)이며 리더보드 점수는 쓰지 않았다.

결정 기준	하루 검사 대상	놓침	헛경보	총비용 5:1	총비용 10:1 (기준)	총비용 20:1
검사 안 함	0	852	0	4,258	8,516	17,033
정상 ×1.0 (제출 CSV 기준)	154	759	61	3,856	7,650	15,239
정상 ×0.5	591	565	305	3,132	5,959	11,613
정상 ×0.3	1,179	371	699	2,556	4,413	8,127
정상 ×0.2	1,720	248	1,117	2,359	3,601	6,085
정상 ×0.1	2,575	87	1,810	**2,244**	2,677	3,543
정상 ×0.05	3,032	31	2,212	2,368	**2,523**	**2,835**
전수 검사	3,800	0	2,948	2,948	2,948	2,948

고른 운영안: 정상 ×0.1(하루 2,575샷 검사, 놓침 87건, 헛경보 1,810건). 기준안 10:1에서 최저는 ×0.05(2,523)이지만 검사 대상이 3,032샷(80%)이라 ×0.1(2,677, 검사 2,575샷 68%)을 골랐다.

비용은 최저와 6% 차이이고 전수 검사(2,948)보다 9% 싸다.

결론은 비용 비율에 민감하다: 5:1이면 ×0.1이 전수 검사보다 24% 싸서 모델이 분명히 도움이 되고(2,244), 10:1이면 이점이 9~14%로 줄어 샷의 70~80%를 검사해야 하고, 20:1이면 ×0.1(3,543)은 전수 검사(2,948)보다 비싸고 ×0.05(2,835)도 4% 차이라 전수 검사와 구별되지 않는다.

처음 보는 입력에서 불량을 구분하는 정보 자체가 약하기 때문이다(AUC 0.75). 그러므로 이 모델은 놓침이 아주 비싼 현장보다 비용 비율이 낮은 현장, 또 같은 조건이 반복되는 라인(제출 CSV 기준 ×1.0이 가장 잘 맞는 구성)에 적합하다.

현장이 실제 비용 비율을 알려 주면 이 표에 바로 대입해 운영 기준을 확정한다.

건수는 놓침·헛경보만 센 것이며 종류를 틀린 건과 종류별 비용 차이는 넣지 않았다.

제출 CSV(가장 높은 확률의 라벨, 정상 ×1.0)와 운영안(정상 ×0.1)은 다르다: CSV는 macro F1을 높이려는 7종 분류이고(×0.1로 낮추면 채점 구조를 반영한 내부 검증 점수가 0.62에서 0.49로 내려간다), 운영안은 놓침 비용을 반영해 불량을 더 자주 부르는 기준이다.

보조로 위험(1−정상 확률) 순 상위 20~30%만 검사하는 방식도 있다(그림 5).

모델을 바꾸면 비용이 줄어드는가 (1,000샷당, 학습 데이터 검증, 10:1 기준). 경보 기준이 같은 ×1.0이면 2안이 1안보다 35% 이상 싸 보인다(새 입력 1,307 대 2,024). 그러나 모델마다 기준을 따로 맞추면 차이가 사라진다.

모델	×1.0 비용 (새 입력 / 새 구간)	자기 최저 비용 (새 입력 / 새 구간)	최저일 때 기준 (새 입력 / 새 구간)
1안	2,024 / 2,218	660 / 732	×0.05 / ×0.1
2안	1,307 / 1,664	684 / 738	×0.1 / ×0.2
전수 검사	776 (모든 샷 재검사)		

두 모델의 최저 비용은 4% 안(새 입력 660~684, 새 구간 732~738)이고, 전수 검사보다 새 입력에서 12~15%, 새 구간에서 5~6% 싸다.

비용을 정하는 것은 모델 종류보다 경보 기준(비용 비율)이다.

5:1이면 1안은 588 / 650으로 절감이 24% / 16%, 20:1이면 737 / 784로 전수 검사와 같거나 나쁘다.

그래도 2안은 입력 25개·숲 2개라 설명이 쉽고 **뒤 사건 입력이 필요 없어 실시간 판정이 가능**하다는 점에서 현장 운영 후보로 둔다.

기준을 현장 비율로 정하는 것은 같다.

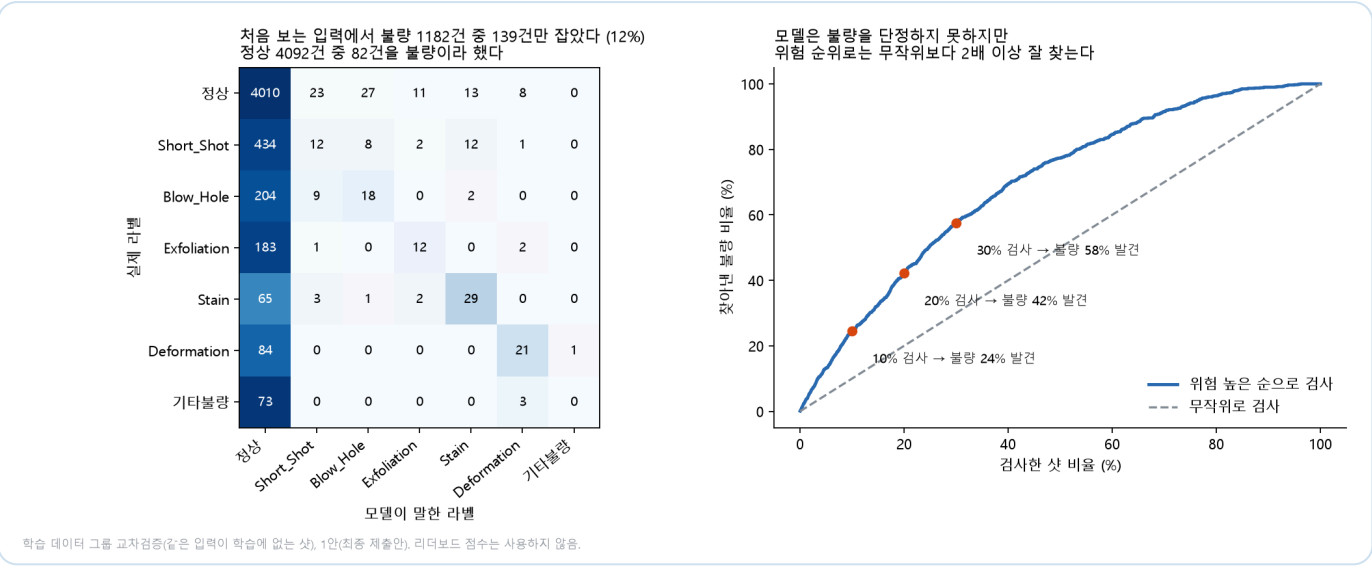


그림 5. 새 입력에서의 혼동행렬(실제 대비 모델 예측)과 위험 순위 곡선. 검사 10/20/30% → 불량 24/42/58% 발견(무작위는 10/20/30%). 한 번의 그룹 교차검증 결과라(불량 139건 포착, 경보 82건) 그림 4의 시드 3개 평균(122건, 73건)과 몇 건 다르다.

8. 불량 원인 분석 (불량 유형 3종)

방법: 불량 종류마다 "그 종류인가 아닌가"로 RF를 따로 학습하고 처음 보는 입력에서 순열 중요도로 중요한 조건을 뽑은 뒤 (그룹 CV AUC: Short_Shot 0.75, Blow_Hole 0.90, Exfoliation 0.83), 그 조건을 구간으로 나눠 구간별 불량률을 직접 셌다.

제품 유형이 불량 종류를 가르므로 유형별로 셌다.

괄호는 Wilson 95% 신뢰구간.

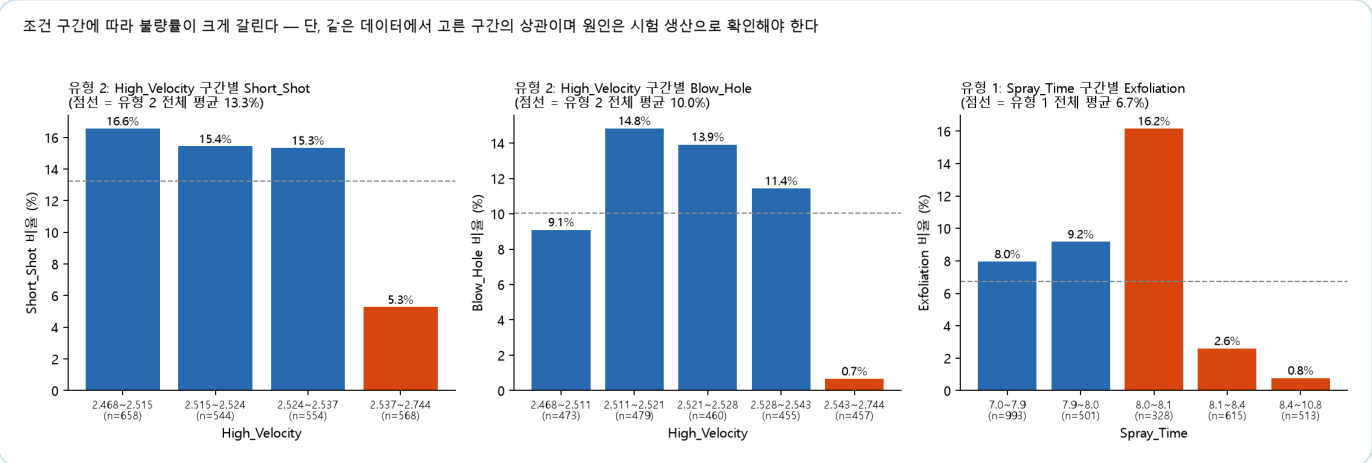


그림 6. 구간별 불량률. 주황 막대는 평균보다 크게 낮거나 높은 구간.

불량(대상)	조건 구간	구간 안	구간 밖	구간 비중
Short_Shot (유형 2, 2,324행)	High_Velocity > 2.537	**5.3%** (3.7~7.4)	15.8% (14.2~17.6)	24%
Blow_Hole (유형 2)	High_Velocity > 2.543	**0.7%** (0.2~1.9)	12.3% (10.9~13.9)	20%
Blow_Hole (유형 2)	Coolant_Temp ≤ 26.4	23.4% (20.0~27.3)	6.2% (5.2~7.4)	22%
Exfoliation (유형 1, 2,950행)	Spray_Time > 8.1	**1.8%** (1.2~2.7)	9.8% (8.5~11.2)	38%
Short_Shot (유형 1)	Melting_Furnace_Temp > 711	2.6% (1.7~4.0)	6.4% (5.5~7.5)	25%

현장 제안: "유형 2 제품에서 High_Velocity를 2.537 초과 범위로 관리하면 Short_Shot이 15.8%에서 5.3%, Blow_Hole이 12.3%에서 0.7%로 줄 가능성이 있다.

유형 1 제품에서 Spray_Time이 8.1을 넘는 샷은 Exfoliation이 9.8%에서 1.8%였다."

한계 (원인이라고 말할 수 없는 이유)

- 구간 경계를 같은 데이터에서 골랐다. 따로 떼어 둔 확인용 데이터가 없어 실제 효과는 이보다 작을 수 있다.
- 센 것은 "그 구간에서 불량이 적었다"는 상관이다. 속도가 높은 샷은 금형 온도·작업 시기·설비 상태와 같이 움직였을 수 있다.
- High_Velocity 값은 몇 개의 값 덩어리로 뭉쳐 있어 설정 묶음의 표지일 수 있고, Spray_Time은 8.0~8.1만 높고 옆은 낮은 비단조 모양이라 우연이나 시기 영향일 수 있다.

  환경 열(공장 온도·습도, 냉각수 온도)은 시기 표지일 가능성이 커 인과로 읽지 않는다(묶음 단위 분석에서 환경 열을 빼면 점수가 가장 크게 하락, −0.012).
- **확인 방법**: 해당 변수만 구간 안팎으로 바꿔 시험 생산(A/B)하고 같은 제품·같은 시기에서 불량률을 비교한다. 그 전까지는 "관리 후보"로만 쓴다.

9. 현장 언어로 번역

- **새로운 조건의 샷**(학습에 같은 입력이 없음): "불량 100건 중 약 10건을 잡고 90건을 놓칩니다.

  정상 100건 중 약 2건을 불량이라 울립니다.

  울린 경보 195건 중 122건(63%)이 진짜 불량이었습니다." 1,000샷으로 환산(불량 22.4%)하면 불량 224건 중 23건을 잡고 정상 776건 중 14건에 헛경보.
- **이미 본 적 있는 조건**이 다시 나오면: 불량 100건 중 58건을 잡습니다(시험 샷의 약 58%가 이 경우).
- **불량 종류별**(새 입력, 종류까지 맞힘): Stain 100건 중 26건, Deformation 106건 중 21건, Blow_Hole 233건 중 18건, Exfoliation 198건 중 10건, Short_Shot 469건 중 12건, 기타불량 76건 중 0건.
- **"불량을 너무 많이 놓치는 것 아닌가"에 대한 답**: 맞다.

  새 입력 기준 1안은 불량 1,182건 중 1,060건(90%)을 놓친다(그림 4). 정확도 79%는 정상이 78%라서 "전부 정상"으로 답해도 나오는 값이라 착시다.

  원인은 입력값만으로 불량을 가르는 정보가 약해서이며(AUC 0.74~0.75, 시험한 모든 모델이 같음), 2안도 52%를 놓친다.

  같은 입력이 학습에 있는 샷(시험의 약 58%)에서는 약 58%를 잡는다.

대응은 두 단계: ① 같은 1안에서 경보 기준만 낮춘다(정상 ×0.1이면 새 입력 불량의 약 90%를 잡지만 정상의 약 12%에 헛경보, 검사 대상이 전체의 약 2/3). ② 앞 사건만으로 실시간 판정이 필요하거나 설명이 우선이면 2안을 쓴다(4·7절). 어느 쪽이든 놓침·헛경보 중 무엇이 비싼지는 현장 비용 비율이 정한다.

- 그래서 "불량이다/아니다" 자동 판정 대신 **"위험 순위 상위 20%를 먼저 검사"**로 쓰는 것을 권한다(7절). 정확도 87%는 정상이 77%라 의미가 작아 단독으로 말하지 않는다.

10. AI 사용과 AI가 틀린 것

AI(Claude)를 코드 작성·실험 설계·결과 해석 보조에 사용했고, 숫자는 모두 직접 실행해 확인한 값만 보고서에 썼다. 무엇을 물었고 무엇을 검증해 기각했는지:

AI 조언	검증 결과
"쌍둥이의 라벨을 그대로 찾아 쓰면 0.65~0.70까지 오른다"	모의 계산으로 약 0.58에 그침(직접 계산해 기각). 규칙상 이웃 라벨은 쓸 수도 없어 이웃 *입력*만 특징으로 채택
"내부 점수(리더보드풍)가 리더보드를 예측한다"	1안은 어림 0.623 대 실제 0.5987로 0.024 높았고 2안은 약 0.02 낮아 오차 방향이 모델마다 달랐다. 낙관 편향을 보정해 해석하고, 내부 점수로 순위를 예측하지 않음
"이동평균·순번 특징·클래스 보정으로 +0.005"	시드·표본 흔들림(0.005~0.03)보다 작거나 규칙 회색지대라 채택하지 않음. 순위 예측("상위권")도 근거가 없어 철회
"탐지율을 올리면 점수도 오른다"(잎 3·5, SMOTE식 보강)	탐지율 63~67%로 올랐지만 점수는 0.6125→0.6033 등으로 내려감. 헛경보가 늘어 정확도·정밀도가 깎임(맞바꿈)
"정상 확률에 ×0.3~0.4를 곱하면 0.6을 넘는다"(다른 AI 제안)	새 입력만 보면 F1 0.25→0.335로 맞지만 리더보드풍은 0.623→0.599(×0.4)·0.580(×0.3)로 내려갔고, 선택·평가를 분리해도 평균 −0.002라 점수용으로 기각. 운영안(놓침 비용 반영)에서만 사용
"다른 구성의 모델과 섞으면 새 입력·탐지율·정확도가 함께 오른다"	1안에 비교 모델 확률을 15~50% 섞어 보니 탐지율은 오르지만 정확도와 점수는 같거나 내려가 세 지표를 동시에 올리는 조합은 없었음(맞바꿈)