주조 불량 유형 예측 — 1조 최종 보고서

포스코 K-뉴딜아카데미 딥러닝 최종 프로젝트 · 7,535샷(학습 5,274 · 시험 2,261) · 지표 macro F1 · 모든 수치는 학습 데이터 검증으로 계산했고 리더보드 점수로 모델을 고르지 않았다

0. 요약

0.623	11%	0.58~0.61	×0.1
리더보드풍 F1 (쌍둥이 58% 반영, 시드 4개)	같은 입력이 없는 새 샷에서 잡는 불량 비율	private 예상 (보수적~중심, SD 0.037)	운영안(정상 확률 배율) 10:1에서 전수 검사 대비 −9%

- **최종 모델**: 랜덤포레스트 + ExtraTrees 확률 평균 + 두 단계 모델(불량 여부 → 불량 종류) 혼합 + 앞뒤 사건의 입력값 40개 추가(입력 25→65개). `python main.py` 한 줄, CPU 약 80초. 중간 리더보드 점수 0.5987(공개 기준선 0.2517).
- **핵심 발견**: 시험 샷의 약 58%는 같은 입력(쌍둥이)이 학습에 있어 93%를 맞힌다. 같은 입력이 없는 새 샷에서는 **불량 1,182건 중 134건(11%)만 잡고 정상 4,092건 중 86건(2.1%)을 불량이라 한다**. 이 한계는 모델 종류와 무관하다(18개 탐지기 AUC 0.72~0.75).
- **현장 제안**: 모델은 "불량이다"를 단정하는 용도가 아니라 **경보 기준을 놓침 비용에 맞춰 낮춰 검사 대상을 고르는 용도**로 쓴다. 하루 3,800샷(사이클 시간으로 계산) 기준 운영안은 정상 확률 ×0.1이고, 놓침 1건=헛경보 10건으로 가정하면 전수 검사보다 9% 싸다(5:1이면 24%, 20:1이면 이점 없음 → **결과는 비용 비율에 민감**, 7절). 현장 운영 후보로 더 단순한 D·A도 함께 검증했고, 경보 기준을 맞추면 세 모델의 최저 비용은 4% 안이다(4·7절). 공정 관리 후보 구간도 제시하되 원인은 시험 생산으로 확인해야 한다.
- **한계**: ① 같은 입력이 없는 새 샷에서는 불량의 11%만 잡는다. ② 최종 모델은 앞뒤 사건의 입력값을 쓰는데, **뒤 사건의 값은 실시간 현장에서는 아직 모르므로** 사후 분석·일괄 선별용이다(앞 사건만 쓰면 이득이 사라진다, 4절 ①). 실시간 적용에는 앞 사건만 쓰는 변형이 필요하다. ③ 비용 비율은 가정이며 현장 값으로 교체해야 한다.
- **규칙 준수**: 특징은 전처리된 입력뿐이며 shot_id·id·Shot 열과 정답에서 만든 값, 원본 불량 기록은 쓰지 않았다. 쌍둥이 묶음은 입력값 비교로 만들어 검증 분할에만 쓴다. 이웃 *입력*은 쓰지만 이웃의 *정답*은 쓰지 않았다. 모델 선택은 학습 데이터 검증으로만 했다.

1. 데이터 문제와 처리

문제	확인한 수치	처리와 이유
식별·상수 열	shot_id·id·Shot 3개, Min/Max 상수 8개	제거(식별 열은 규칙상 특징 불가, 상수는 정보 없음). 32열 → 21열 + 표시 열 4개 = 25개
결측	공장 온도·습도 90행(전부 제품 유형 2, 두 덩어리)	앞뒤 실측 30개씩의 중앙값으로 채움 + 결측 표시 열. 방식·창 크기 간 점수 차 0.004(표준편차 0.03 이내)
이상한 값	속도 0·긴 사이클(설비 정지로 보임), 이상치 15행	지우지 않고 표시 열만 추가. 지워도 점수 차가 표준편차 안쪽
중복 행(쌍둥이)	입력 21개가 앞 행과 같은 행 3,174개(42%), 같은 묶음 안 라벨 일치 97.8%	행은 유지하고 묶음 번호를 검증 분할에만 사용(특징 아님). 시험 데이터도 58%가 같은 구조
클래스 불균형	정상 77.6%, 기타불량 76건·Stain 100건	class_weight(balanced의 0.5제곱). 정확도가 아닌 macro F1 사용
제품·시기 교란	shot 4208에서 제품 전환, 불량 종류가 제품·시기에 몰림(400샷 블록 불량률 1.8~51%)	검증을 묶음·시간순으로 따로 측정(6절), 원인 분석은 제품 유형별로 수행(8절)

2. 설계 카드 (MLP)

입력 25개 → 은닉 128 → 64 → 출력 7, 활성화 ReLU(음수는 0으로 막아 단순한 꺾은선 조합으로 비선형을 표현), 드롭아웃 0.2(과적합 방지), 손실은 클래스 가중 교차엔트로피(희귀 불량을 놓치지 않게), Adam 학습률 1e-3(기본값에서 시작, 손실이 안정적으로 내려감), 가중치 감쇠 1e-4. epoch는 검증 손실이 최저인 18에서 멈춘다(그림 1). 입력은 학습 구간 평균·표준편차로 표준화.

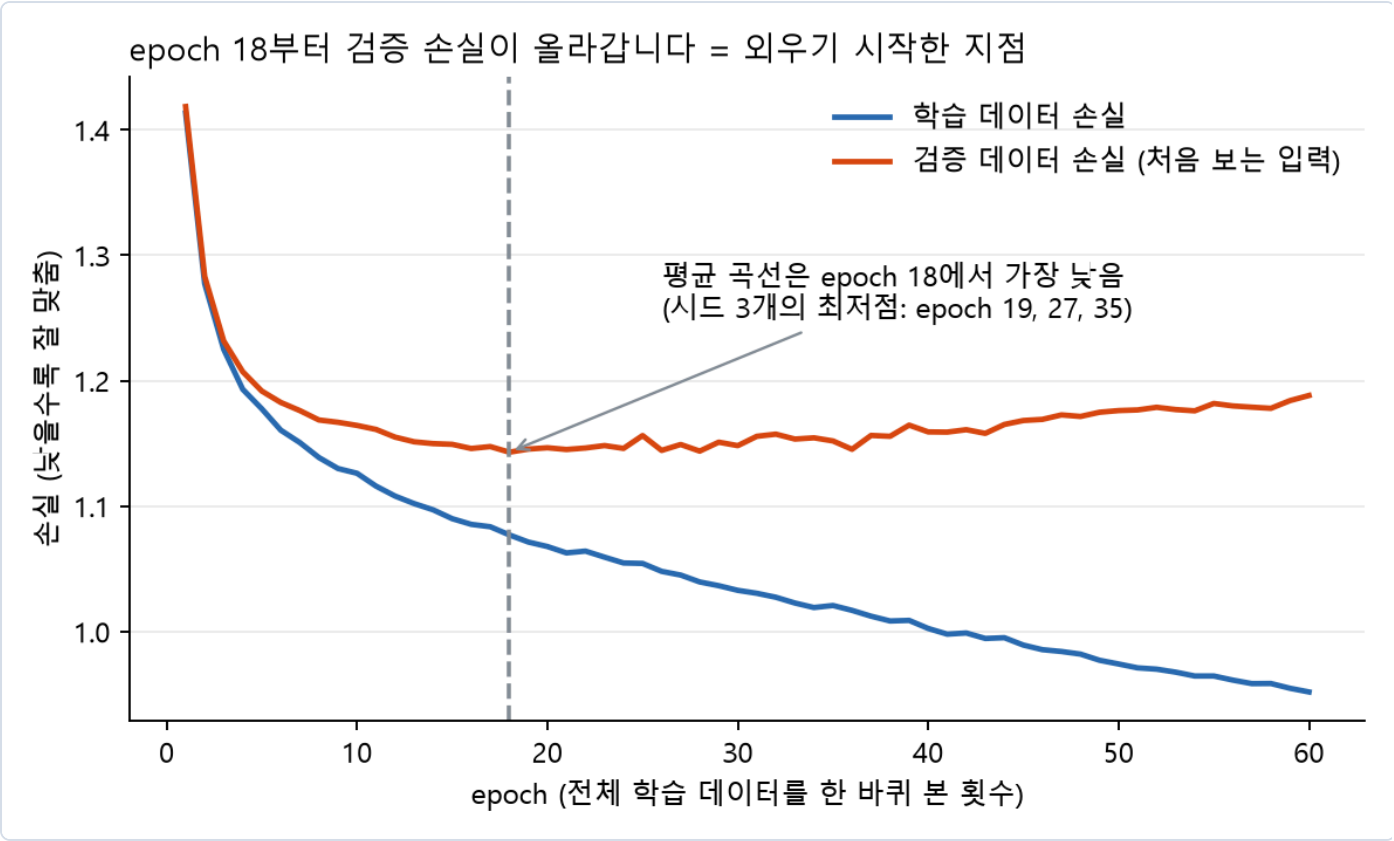


그림 1. 학습 손실은 계속 내려가지만 검증 손실은 epoch 18(1.143)에서 최저, epoch 60에서 1.188로 4% 상승 → 과적합 시작점. 시드 3개 최저점 19·27·35.

3. 베이스라인 대조

모델 (쌍둥이 묶음 검증, 새 입력)	macro F1	비고
공개 기준선(로지스틱 + class_weight, 강사 제공)	0.2517	리더보드 구조
로지스틱 / RF / HGB (잎 10)	0.287 / 0.326 / 0.305	새 입력만 맞히는 어려운 검증
MLP	0.277(탐지율 54%)	리더보드 구조에서는 0.289로 트리(0.58)보다 훨씬 낮음

MLP가 리더보드 구조에서 낮은 이유: 시험의 58%는 학습에 같은 입력이 있는데 트리는 이를 외워 93% 맞히고 MLP는 외우지 못한다. 반대로 새 입력에서는 MLP(0.277)와 트리(0.279)가 같다. 즉 점수 차는 모델 품질이 아니라 "같은 입력을 외울 수 있는가"에서 나온다.

4. 비교 실험 3종 (한 번에 하나만 바꿈, H 대비 내부 점수 차이)

바꾼 것	결과	해석
① 앞뒤 사건 입력값 특징 (없음 → 40개)	+0.0045 (앞만 −0.0002, 뒤만 −0.0015)	유일하게 일관된 이득. 앞뒤 샷의 공정 상태가 현재 샷의 불량과 이어진다고 해석. 라벨은 쓰지 않음
② 클래스 가중치 강도 (0.3 / 0.75 / 1.0, 기본 0.5)	−0.0002 / +0.0006 / −0.0007	노이즈 → 0.5 유지. 강하게 줄수록 탐지는 늘지만 헛경보도 늘어 점수는 그대로
③ 잎 크기 (최소 샘플 1 → 2)	0.608 vs 0.610	동일 → 1 유지(탐지 57.4%, 정확도 87.2%)

이 밖에 나무 수 900, max_features, 부트스트랩, 이웃 ±2~3, 시기 군집, 클래스별 탐지기, SMOTE식 보강, 이동평균 등 20여 가지를 시험했으나 모두 ±0.005 이내였고(시드 흔들림 0.005), 어떤 조합도 시험 데이터 예측이 시드에 따라 평균 3행(0.1%) 넘게 바뀌지 않았다. H가 평평한 정점이다.

최종 모델 선택 근거(학습 데이터 검증만 사용, 같은 5-분할·시드 42·0·1·2). H와 팀 내에서 만든 다른 구성 4종(이웃 입력 없음, RF 또는 ET+RF)을 같은 틀에서 비교했다. 점수는 시험 구조(쌍둥이 58.4%)로 가중한 리더보드풍 F1, 비교의 근거는 순위가 아니라 시드별 반복과 private 크기(1,131샷) 표본 흔들림이다.

모델	리더보드풍 F1 (시드 4개)	새 입력 F1	놓침 / 헛경보 (1,130샷)	H보다 높을 확률 (표본 1,131샷)
H (최종)	**0.623** (0.616 0.620 0.635 0.622)	0.252	106 / **23**	–
ET잎1+RF잎6(합침)	0.614 (0.603 0.608 0.629 0.616)	0.296	93 / 38	31%
RF잎1 (쌍둥이 한 행으로 합쳐 학습)	0.601 (0.593 0.595 0.613 0.602)	0.309	82 / 57	15%
RF잎1+RF잎6, 기타불량×1.5	0.557	0.326	65 / 106	2%
RF 잎3 단독	0.550	0.316	67 / 112	1%

H는 시드 4개 모두에서 가장 높았다. 새 입력에서는 비교 모델이 불량을 더 공격적으로 불러 더 잡지만(탐지율 24~49% vs H 11%) 헛경보와 점수 손실이 따른다. 불량 구분 능력 자체(AUC)는 다섯 모델 모두 0.74~0.75로 같다. H와 상위 두 모델의 차이(0.009~0.022)는 표본 흔들림(SD 0.037) 안이라 우열이 확실하지는 않으며, H에 비교 모델 확률을 15~50% 섞어도 세 지표(점수·정확도·새 입력)를 동시에 올리지는 못했다. 같은 효과(탐지 증가)는 H의 경보 기준 하나로 더 적은 손실로 얻는다(7절).

제출용 H와 현장 검토용 D·A의 비교(같은 학습 데이터 검증 두 가지: 쌍둥이를 같은 쪽에 두는 "새 입력" 5분할, 연속 100샷 구간을 통째로 떼는 "새 생산 구간" 5분할, 시드 7·123·2026 평균). D = RF 잎1 + RF 잎6 확률 평균, 기타불량 ×1.5. A = RF 잎3 한 개(balanced_subsample). 경보 기준은 셋 다 ×1.0.

모델	리더보드풍 F1	새 입력 F1 / 탐지율	새 생산 구간 F1 / 탐지율	구조와 용도
H (제출)	**0.623**	0.258 / 10.3%	0.136 / **1.2%**	숲 6개·2단계·앞뒤 입력 65개. 채점 구조(쌍둥이 58%)에 최적, 뒤 사건 입력이 필요해 사후 분석용
D (균형형)	0.557	**0.323** / 48.0%	**0.235** / 31.0%	숲 2개·25개 입력. 불량을 적극 부름, 실시간 가능
A (기본형)	0.550	0.314 / 44.2%	0.226 / 26.8%	숲 1개·설정 3개. 가장 단순해 설명·유지가 쉬움

채점 구조에서는 외우는 능력이 점수를 가르므로 H가 높고, 처음 보는 입력과 새 생산 구간에서는 D·A가 낫다. **H는 새 생산 구간에서 불량을 거의 못 잡는다(탐지율 1.2%)**. 따라서 제출 CSV는 H, 현장 운영 후보는 D·A로 구분해 제시하고, 둘의 차이를 줄이는 장치가 경보 기준이다(7절).

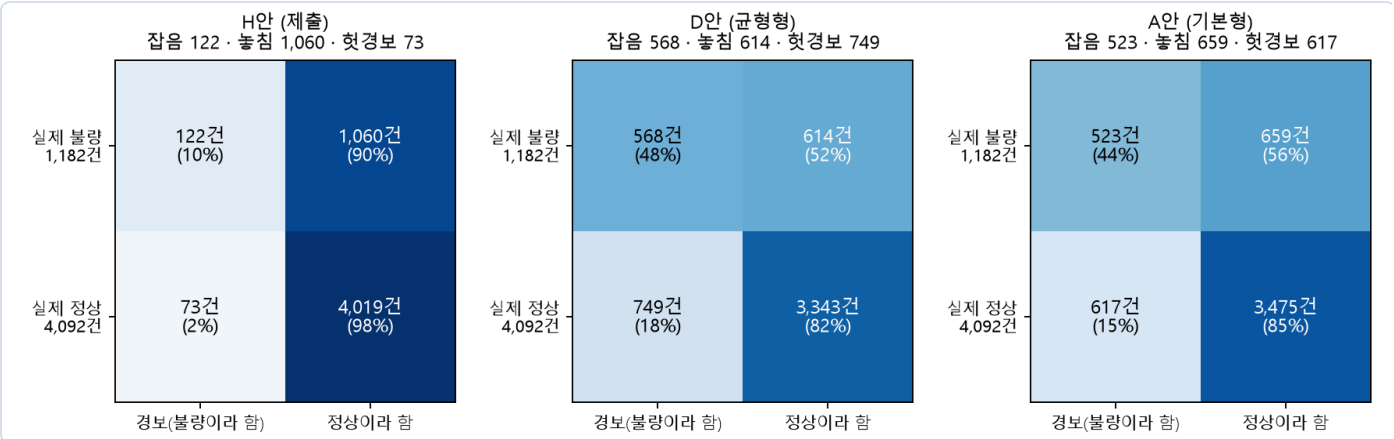


그림 6. 새 입력(쌍둥이를 같은 쪽에 둔 5분할) 기준 정상/불량 2×2 표, 건수는 시드 7·123·2026 평균이며 경보 기준 ×1.0. H는 불량 1,182건 중 122건(10%)을 잡고 정상 4,092건 중 73건에 헛경보를 낸다. D·A는 불량을 44~48% 잡는 대신 헛경보가 15~18%다. 본문 다른 곳의 H 수치(134건/86건)는 시드 4개 평균이라 몇 건 다르다.

5. 학습곡선 (데이터를 더 모아야 하는가)

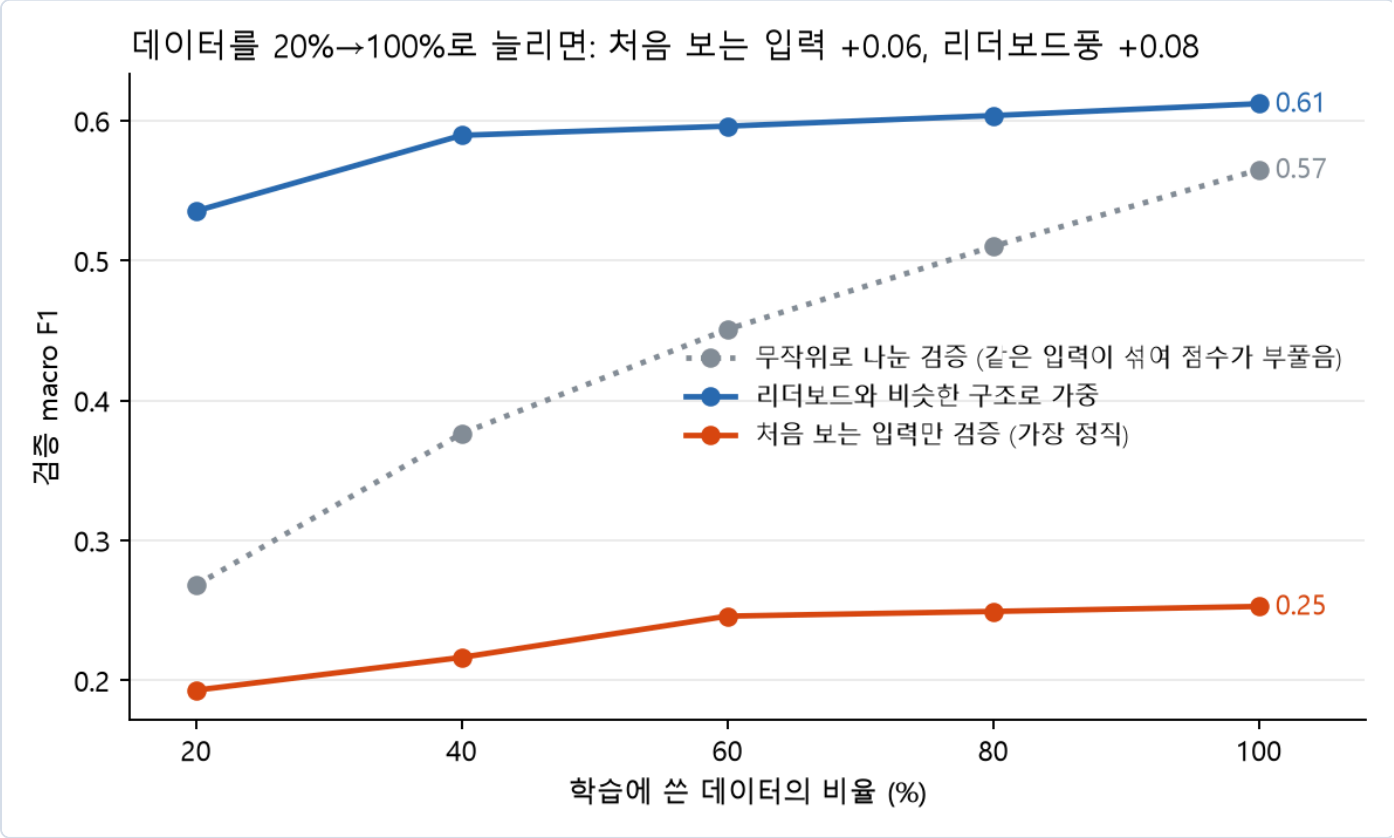


그림 2. 학습 데이터 비율에 따른 점수(H안, 시드 2개). 새 입력 0.193→0.253(60% 이후 평평). 리더보드풍 0.536→0.612, 무작위 CV 0.268→0.565(같은 입력이 학습에 들어와 크게 오름).

결론: 데이터를 더 모으면 "이미 본 조건"의 점수는 오르지만 새 조건의 점수는 거의 안 오른다. 새 조건을 잡으려면 데이터 양보다 **불량과 정상을 가르는 새 측정**이 필요하다. 가정 기반 계산(불량 샷에서 평균 d 표준편차 높은 가상 측정을 추가, 실제 결과 아님): d=0.5는 점수 0.268→0.269로 변화 없고, d=1이면 0.297, d=2이면 0.400(탐지율 14%→41%). 구분력이 표준편차의 약 1배 이상인 측정을 찾아야 의미가 있다.

6. 분할 방식 비교 (어느 쪽이 배포 성능인가)

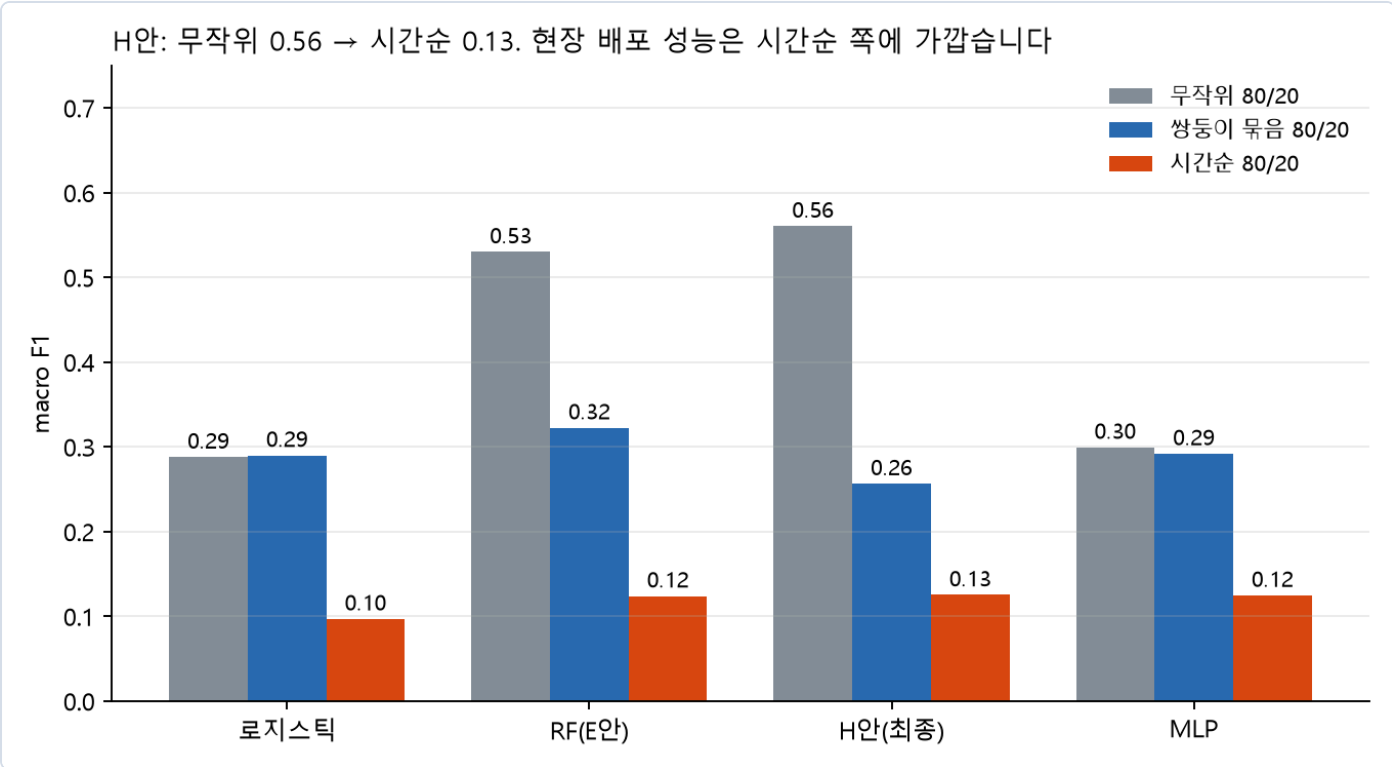


그림 3. macro F1 / 불량 탐지율 / 정확도. 무작위·묶음은 80/20 시드 5개 평균, 시간순은 shot 순 앞 80%로 학습해 뒤 20%를 검증.

모델	무작위 80/20	쌍둥이 묶음 80/20	시간순 80/20
로지스틱	0.288	0.290	0.097
RF	0.530	0.322	0.124
최종(H)	0.560	0.256	0.125 (탐지 0%)
MLP	0.299	0.292	0.125

외우는 모델일수록 무작위에서 부풀고, 시간순에서는 모든 모델이 "전부 정상"(0.125)에 가깝다. **현장 배포 성능에 가까운 쪽은 시간순**이다. 리더보드는 시험 샷이 생산 순서에 섞여 있어 무작위 쪽에 가깝다. 시간순 구간(shot 6009~7535)은 전부 제품 유형 2이고 학습에 이 제품이 1,269행뿐이어서 "새 시기의 같은 제품"을 거의 못 본 시험이다. 그러므로 최종 점수(private 1,131행, 흔들림 SD 약 0.03)를 현장 성능으로 읽으면 안 된다. 연속 100샷 구간을 통째로 떼는 "새 생산 구간" 검증(4절 표)에서도 같은 결과다: H는 F1 0.136·탐지율 1.2%, D·A는 0.235·0.226(탐지 31%·27%).

분할에 따라 모델 순위가 바뀐다(4절 비교 모델 포함): 무작위·리더보드풍 기준에서는 H가 0.623으로 가장 높고, 쌍둥이 묶음(새 입력) 기준에서는 비교 모델이 0.30~0.33으로 H(0.25)보다 높다. 시험 샷의 58%가 학습에 같은 입력이 있는 구조(private 58.4%, 입력으로 센 값)이므로 최종 채점은 리더보드풍에 가깝다고 보고 H를 택했고, 시드 4개 모두에서 H가 위였다. 대신 새 입력 약점을 한계로 명시하고 운영안은 경보 기준으로 보완했다. 예상 private 점수(H): 중심 약 0.61, 보수적 약 0.58(표본 흔들림 SD 0.037, 내부 어림이 실제보다 0.01~0.02 높게 나온 경향 반영).

7. 운영 기준 (비용표)

가정과 출처. 하루 생산량은 계산했다: 데이터의 사이클 시간 중앙값 22.6초, 24시간 연속 가동이면 86,400÷22.6 ≈ **하루 3,800샷**(가동 시간은 가정, 8시간 교대면 약 1,270샷). 불량률 22.4%는 학습 데이터에서 계산한 처음 보는 입력 기준이라 하루 불량 약 850건·정상 약 2,950건이다. 비용 비율은 현장 자료가 없어 가정한다: 헛경보(정상 샷을 불량으로 불러 한 번 더 검사) 1건 = 1, 놓친 불량 1건 = 5·10·20. 비용 비율은 부품의 안전 등급·보증/리콜 비용·재검사 비용에 따라 현장마다 다르므로 정확한 값을 알 수 없다. 그래서 **기준안은 10:1**로 두고(품질비용 이론의 "1-10-100 경험 법칙", 검사·재작업 대비 고객에게 나간 불량의 비용이 약 10배, 엄밀한 표준 수치는 아님) 5:1과 20:1에서도 같은 표를 만들어 결론이 유지되는지 본다. **결정 기준**은 정상 확률에 곱하는 배율(작을수록 불량으로 더 자주 부른다, `main.py`의 `ALERT_NORMAL_SCALE`)이다. 건수는 학습 데이터 검증(처음 보는 입력, 시드 4개 평균)이며 리더보드 점수는 쓰지 않았다.

결정 기준	하루 검사 대상	놓침	헛경보	총비용 5:1	총비용 10:1 (기준)	총비용 20:1
검사 안 함	0	852	0	4,258	8,516	17,033
정상 ×1.0 (제출 CSV 기준)	154	759	61	3,856	7,650	15,239
정상 ×0.5	591	565	305	3,132	5,959	11,613
정상 ×0.3	1,179	371	699	2,556	4,413	8,127
정상 ×0.2	1,720	248	1,117	2,359	3,601	6,085
정상 ×0.1	2,575	87	1,810	**2,244**	2,677	3,543
정상 ×0.05	3,032	31	2,212	2,368	**2,523**	**2,835**
전수 검사	3,800	0	2,948	2,948	2,948	2,948

고른 운영안: 정상 ×0.1(하루 2,575샷 검사, 놓침 87건, 헛경보 1,810건). 기준안 10:1에서 최저는 ×0.05(2,523)이지만 검사 대상이 3,032샷(80%)이라 ×0.1(2,677, 검사 2,575샷 68%)을 골랐다. 비용은 최저와 6% 차이이고 전수 검사(2,948)보다 9% 싸다. **결론은 비용 비율에 민감하다**: 5:1이면 ×0.1이 전수 검사보다 24% 싸서 모델이 분명히 도움이 되고(2,244), 10:1이면 이점이 9~14%로 줄어 샷의 70~80%를 검사해야 하고, 20:1이면 ×0.1(3,543)은 전수 검사(2,948)보다 비싸고 ×0.05(2,835)도 4% 차이라 전수 검사와 구별되지 않는다. 처음 보는 입력에서 불량을 구분하는 정보 자체가 약하기 때문이다(AUC 0.75). 그러므로 이 모델은 놓침이 아주 비싼 현장보다 비용 비율이 낮은 현장, 또 같은 조건이 반복되는 라인(제출 CSV 기준 ×1.0이 가장 잘 맞는 구성)에 적합하다. **현장이 실제 비용 비율을 알려 주면 이 표에 바로 대입해 운영 기준을 확정한다.** 건수는 놓침·헛경보만 센 것이며 종류를 틀린 건과 종류별 비용 차이는 넣지 않았다. 제출 CSV(가장 높은 확률의 라벨, 정상 ×1.0)와 운영안(정상 ×0.1)은 다르다: CSV는 macro F1을 높이려는 7종 분류이고(×0.1로 낮추면 리더보드풍 점수가 0.62에서 0.49로 내려간다), 운영안은 놓침 비용을 반영해 불량을 더 자주 부르는 기준이다. 보조로 위험(1−정상 확률) 순 상위 20~30%만 검사하는 방식도 있다(그림 4).

모델을 바꾸면 비용이 줄어드는가 (1,000샷당, 학습 데이터 검증, 10:1 기준). 경보 기준이 같은 ×1.0이면 D·A가 H보다 35% 이상 싸 보인다. 그러나 모델마다 기준을 따로 맞추면 차이가 사라진다.

모델	×1.0 비용 (새 입력 / 새 구간)	자기 최저 비용 (새 입력 / 새 구간)	최저일 때 기준 (새 입력 / 새 구간)
H	2,024 / 2,218	660 / 732	×0.05 / ×0.1
D	1,307 / 1,664	684 / 738	×0.1 / ×0.2
A	1,367 / 1,726	658 / 733	×0.1 / ×0.1
전수 검사	776 (모든 샷 재검사)		

세 모델의 최저 비용은 4% 안(새 입력 658~684, 새 구간 732~738)이고, 전수 검사보다 새 입력에서 12~15%, 새 구간에서 5~6% 싸다. **비용을 정하는 것은 모델 종류보다 경보 기준(비용 비율)이다.** 5:1이면 H는 588 / 650으로 절감이 24% / 16%, 20:1이면 737 / 784로 전수 검사와 같거나 나쁘다. 그래도 D·A는 입력 25개·숲 1~2개라 설명이 쉽고 **뒤 사건 입력이 필요 없어 실시간 판정이 가능**하다는 점에서 현장 운영 후보로 둔다. 기준을 현장 비율로 정하는 것은 같다.

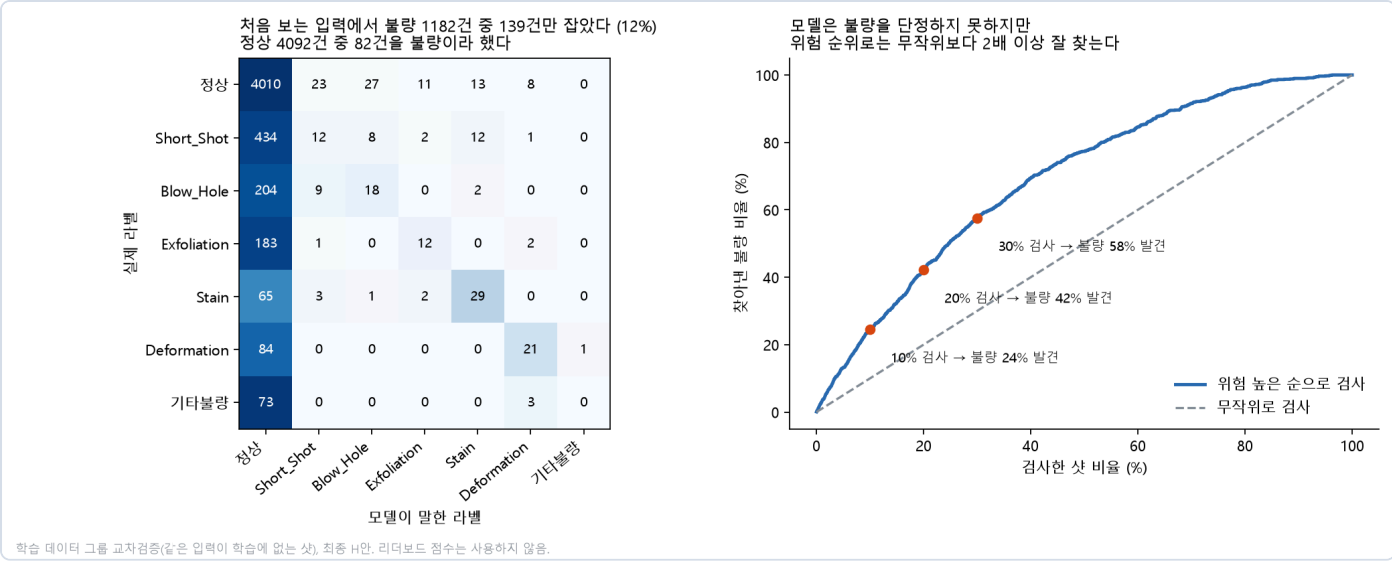


그림 4. 새 입력에서의 혼동행렬(실제 대비 모델 예측)과 위험 순위 곡선. 검사 10/20/30% → 불량 24/42/58% 발견(무작위는 10/20/30%). 한 번의 그룹 교차검증 결과라 본문 시드 평균과 몇 건 다르다.

8. 불량 원인 분석 (불량 유형 3종)

방법: 불량 종류마다 "그 종류인가 아닌가"로 RF를 따로 학습하고 처음 보는 입력에서 순열 중요도로 중요한 조건을 뽑은 뒤 (그룹 CV AUC: Short_Shot 0.75, Blow_Hole 0.90, Exfoliation 0.83), 그 조건을 구간으로 나눠 구간별 불량률을 직접 셌다. 제품 유형이 불량 종류를 가르므로 유형별로 셌다. 괄호는 Wilson 95% 신뢰구간.

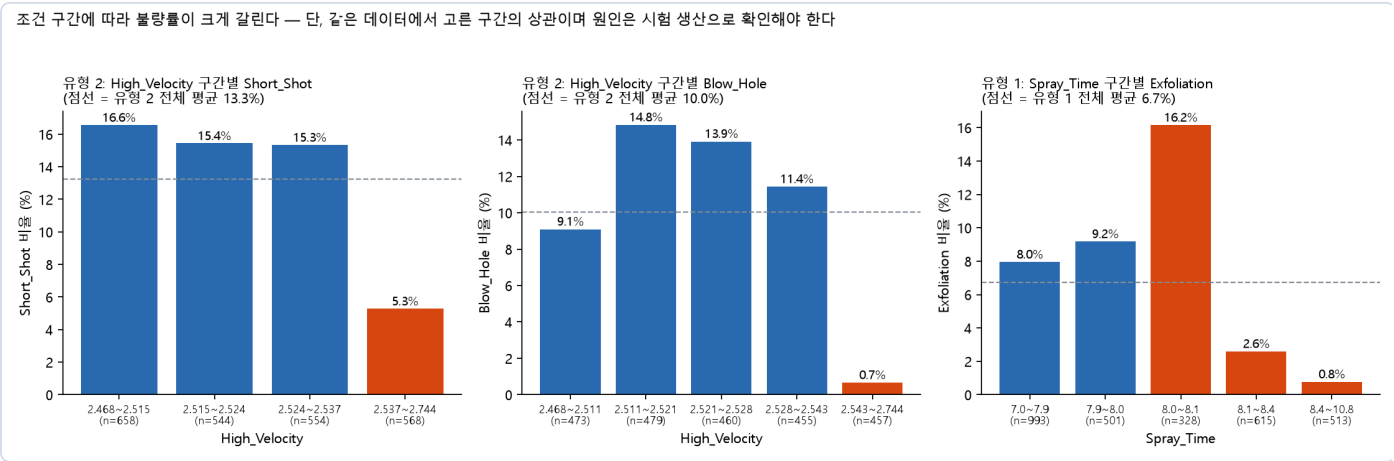


그림 5. 구간별 불량률. 주황 막대는 평균보다 크게 낮거나 높은 구간.

불량(대상)	조건 구간	구간 안	구간 밖	구간 비중
Short_Shot (유형 2, 2,324행)	High_Velocity > 2.537	**5.3%** (3.7~7.4)	15.8% (14.2~17.6)	24%
Blow_Hole (유형 2)	High_Velocity > 2.543	**0.7%** (0.2~1.9)	12.3% (10.9~13.9)	20%
Blow_Hole (유형 2)	Coolant_Temp ≤ 26.4	23.4% (20.0~27.3)	6.2% (5.2~7.4)	22%
Exfoliation (유형 1, 2,950행)	Spray_Time > 8.1	**1.8%** (1.2~2.7)	9.8% (8.5~11.2)	38%
Short_Shot (유형 1)	Melting_Furnace_Temp > 711	2.6% (1.7~4.0)	6.4% (5.5~7.5)	25%

현장 제안: "유형 2 제품에서 High_Velocity를 2.537 초과 범위로 관리하면 Short_Shot이 15.8%에서 5.3%, Blow_Hole이 12.3%에서 0.7%로 줄 가능성이 있다. 유형 1 제품에서 Spray_Time이 8.1을 넘는 샷은 Exfoliation이 9.8%에서 1.8%였다."

한계 (원인이라고 말할 수 없는 이유)

- 구간 경계를 같은 데이터에서 골랐다. 따로 떼어 둔 확인용 데이터가 없어 실제 효과는 이보다 작을 수 있다.
- 센 것은 "그 구간에서 불량이 적었다"는 상관이다. 속도가 높은 샷은 금형 온도·작업 시기·설비 상태와 같이 움직였을 수 있다.
- High_Velocity 값은 몇 개의 값 덩어리로 뭉쳐 있어 설정 묶음의 표지일 수 있고, Spray_Time은 8.0~8.1만 높고 옆은 낮은 비단조 모양이라 우연이나 시기 영향일 수 있다. 환경 열(공장 온도·습도, 냉각수 온도)은 시기 표지일 가능성이 커 인과로 읽지 않는다(묶음 단위 분석에서 환경 열을 빼면 점수가 가장 크게 하락, −0.012).
- **확인 방법**: 해당 변수만 구간 안팎으로 바꿔 시험 생산(A/B)하고 같은 제품·같은 시기에서 불량률을 비교한다. 그 전까지는 "관리 후보"로만 쓴다.

9. 현장 언어로 번역

- **새로운 조건의 샷**(학습에 같은 입력이 없음): "불량 100건 중 약 11건을 잡고 89건을 놓칩니다. 정상 100건 중 약 2건을 불량이라 울립니다. 울린 경보 220건 중 134건(61%)이 진짜 불량이었습니다." 1,000샷으로 환산(불량 22.4%)하면 불량 224건 중 25건을 잡고 정상 776건 중 16건에 헛경보.
- **이미 본 적 있는 조건**이 다시 나오면: 불량 100건 중 58건을 잡습니다(시험 샷의 약 58%가 이 경우).
- **불량 종류별**(새 입력, 종류까지 맞힘): Stain 100건 중 26건, Deformation 106건 중 21건, Blow_Hole 233건 중 18건, Exfoliation 198건 중 10건, Short_Shot 469건 중 12건, 기타불량 76건 중 0건.
- 그래서 "불량이다/아니다" 자동 판정 대신 **"위험 순위 상위 20%를 먼저 검사"**로 쓰는 것을 권한다(7절). 정확도 87%는 정상이 77%라 의미가 작아 단독으로 말하지 않는다.

10. AI 사용과 AI가 틀린 것

AI(Claude)를 코드 작성·실험 설계·결과 해석 보조에 사용했고, 숫자는 모두 직접 실행해 확인한 값만 보고서에 썼다. 무엇을 물었고 무엇을 검증해 기각했는지:

AI 조언	검증 결과
"쌍둥이의 라벨을 그대로 찾아 쓰면 0.65~0.70까지 오른다"	모의 계산으로 약 0.58에 그침(직접 계산해 기각). 규칙상 이웃 라벨은 쓸 수도 없어 이웃 *입력*만 특징으로 채택
"내부 점수(리더보드풍)가 리더보드를 예측한다"	E·F·H 모두 실제 public보다 0.003~0.012 높았고, 1회차만 0.026 낮았다. 낙관 편향을 보정해 해석하고, 내부 점수로 순위를 예측하지 않음
"이동평균·순번 특징·클래스 보정으로 +0.005"	시드·표본 흔들림(0.005~0.03)보다 작거나 규칙 회색지대라 채택하지 않음. 순위 예측("상위권")도 근거가 없어 철회
"탐지율을 올리면 점수도 오른다"(잎 3·5, SMOTE식 보강)	탐지율 63~67%로 올랐지만 점수는 0.6125→0.6033 등으로 내려감. 헛경보가 늘어 정확도·정밀도가 깎임(맞바꿈)
"정상 확률에 ×0.3~0.4를 곱하면 0.6을 넘는다"(다른 AI 제안)	새 입력만 보면 F1 0.25→0.335로 맞지만 리더보드풍은 0.623→0.599(×0.4)·0.580(×0.3)로 내려갔고, 선택·평가를 분리해도 평균 −0.002라 점수용으로 기각. 운영안(놓침 비용 반영)에서만 사용
"다른 구성의 모델과 섞으면 새 입력·탐지율·정확도가 함께 오른다"	H에 비교 모델 확률을 15~50% 섞어 보니 탐지율은 오르지만 정확도와 점수는 같거나 내려가 세 지표를 동시에 올리는 조합은 없었음(맞바꿈)